
COMPTE-RENDU DU DEVOIR 3

Vincent Matthys

1 HMM implementation

1.0 Notations

On désignera par M le nombre d'états cachés (4 dans notre cas). On notera $\mathbf{u} = \{u_t\}_{t \in \llbracket 1; T \rrbracket}$, $\mathbf{q} = \{q_t\}_{t \in \llbracket 1; T \rrbracket}$, $\boldsymbol{\theta} = (\pi, A, \boldsymbol{\mu}, \boldsymbol{\Sigma})$ où $\boldsymbol{\mu} = \{\mu_k\}_{k \in \llbracket 1; M \rrbracket}$ et $\boldsymbol{\Sigma} = \{\Sigma_k\}_{k \in \llbracket 1; M \rrbracket}$. On utilisera également le *one-hot encoding* sur \mathbf{q} , de sorte que q_t^i , variable binaire, représente la i^{e} composante de q_t .

1.1

Le problème de l'inférence dans la chaîne de Markov modélisée, à savoir le calcul de $p(\mathbf{q} \mid \mathbf{u})$ est appréhendable par le calcul de la marginale $p(q_t \mid \mathbf{u})$ suivant :

$$\begin{aligned}
 p(q_t \mid \mathbf{u}) &= \frac{p(\mathbf{u} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
 &= \frac{p(u_1, \dots, u_t \mid q_t)p(u_{t+1}, \dots, u_T \mid q_t)p(q_t)}{p(\mathbf{u})} \quad u_1, \dots, u_t \perp\!\!\!\perp u_{t+1}, \dots, u_T \mid q_t \\
 &= \frac{p(u_1, \dots, u_t, q_t)p(u_{t+1}, \dots, u_T \mid q_t)}{p(\mathbf{u})} \\
 &= \frac{\alpha_t(q_t)\beta_t(q_t)}{p(\mathbf{u})} \\
 &= \frac{\alpha_t(q_t)\beta_t(q_t)}{\sum_{q_t} \alpha_t(q_t)\beta_t(q_t)} \\
 &= \frac{\alpha_t(q_t)\beta_t(q_t)}{\sum_{q_T} \alpha_T(q_T)} \quad \text{puisque} \quad p(\mathbf{u}) = \sum_{q_T} p(q_T, \mathbf{u}) = \sum_{q_T} \alpha_T(q_T)
 \end{aligned} \tag{1}$$

avec $\alpha_t(q_t) = p(u_1, \dots, u_t, q_t)$ et $\beta_t(q_t) = p(u_{t+1}, \dots, u_T \mid q_t)$

On peut alors aussi exprimer $p(q_t, q_{t+1} \mid \mathbf{u})$ en fonction de α_t et β_t :

$$\begin{aligned}
p(q_t, q_{t+1} \mid \mathbf{u}) &= \frac{p(\mathbf{u} \mid q_t, q_{t+1})p(q_t, q_{t+1})}{p(\mathbf{u})} \\
&= \frac{p(\mathbf{u} \mid q_t, q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t \mid q_t, q_{t+1})p(u_{t+1}, \dots, u_T \mid q_t, q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t \mid q_t)p(u_{t+1}, \dots, u_T \mid q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t \mid q_t)p(u_{t+1} \mid q_{t+1})p(u_{t+2}, \dots, u_T \mid q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t, q_t)p(u_{t+1} \mid q_{t+1})p(u_{t+2}, \dots, u_T \mid q_{t+1})p(q_{t+1} \mid q_t)}{p(\mathbf{u})} \\
&= \frac{\alpha_t(q_t)p(u_{t+1} \mid q_{t+1})\beta_t(q_{t+1})A_{q_t, q_{t+1}}}{p(\mathbf{u})}
\end{aligned} \tag{2}$$

où $A_{q_t, q_{t+1}} = p(q_{t+1} \mid q_t)$ et $p(u_{t+1} \mid q_{t+1})$ suit une loi gaussienne.

À des fins d'implémentation, on considérera les logarithmes des α et β , $\tilde{\alpha}$ et $\tilde{\beta}$ de sorte que les formules de récursion peuvent se réécrire :

$$\begin{cases} \ln \alpha_t(q_t) = \ln p(u_t \mid q_t) + \ln \sum_{q_{t-1}} (e^{\ln \alpha_{t-1}(q_{t-1})} A_{q_{t-1}, q_t}) \\ \ln \beta_t(q_t) = \ln \sum_{q_{t+1}} (e^{\ln \beta_{t+1}(q_{t+1})} A_{q_t, q_{t+1}} p(y_{t+1} \mid q_{t+1})) \end{cases} \tag{3}$$

$$\begin{cases} \tilde{\alpha}_t(q_t) = \ln p(u_t \mid q_t) + \ln \sum_{q_{t-1}} (e^{\tilde{\alpha}_{t-1}(q_{t-1})} A_{q_{t-1}, q_t}) \\ \tilde{\beta}_t(q_t) = \ln \sum_{q_{t+1}} (e^{\tilde{\beta}_{t+1}(q_{t+1})} A_{q_t, q_{t+1}} p(y_{t+1} \mid q_{t+1})) \end{cases} \tag{4}$$

et que la tâche d'inférence dite de *smoothing* en équation (1) s'écrit :

$$\begin{aligned} \ln p(q_t \mid \mathbf{u}) &= \ln \alpha_t(q_t) + \ln \beta_t(q_t) - \ln \sum_{q_T} \alpha_T(q_T) \\ \ln p(q_t \mid \mathbf{u}) &= \tilde{\alpha}_t(q_t) + \tilde{\beta}_t(q_t) - \ln \sum_{q_T} e^{\tilde{\alpha}_T(q_T)} \end{aligned} \tag{5}$$

La tâche d'inférence dite de *filtering* est également ajoutée en normalisant α_t :

$$\alpha_t^{\text{norm}}(q_t) = p(q_t \mid u_1, \dots, u_t) = \frac{\alpha_t(q_t)}{\sum_{q_t} \alpha_t(q_t)}$$

et est disponible par le calcul des α_{norm} dans le code fourni.

1.2




FIGURE 1 – Smoothing result for the first 100 datapoints

1.3

On exprime la log-vraisemblance incomplète de la manière suivante :

$$\begin{aligned}
 \ell(\boldsymbol{\theta}; \mathbf{u}) &= \ln \sum_{\mathbf{q}} p(\mathbf{q}, \mathbf{u} \mid \boldsymbol{\theta}) \\
 &= \ln \sum_{\mathbf{q}} r(\mathbf{q} \mid \mathbf{u}) \frac{p(\mathbf{q}, \mathbf{u} \mid \boldsymbol{\theta})}{r(\mathbf{q} \mid \mathbf{u})} \quad \text{pour } r \text{ quelconque} \\
 &\geq \sum_{\mathbf{q}} r(\mathbf{q} \mid \mathbf{u}) \ln \frac{p(\mathbf{q}, \mathbf{u} \mid \boldsymbol{\theta})}{r(\mathbf{q} \mid \mathbf{u})} \quad \text{par l'inégalité de Jensen} \\
 &\geq \mathbb{E}_r[\ell_c(\boldsymbol{\theta}; \mathbf{q}, \mathbf{u})] - H(r(\mathbf{q} \mid \mathbf{u})) = \mathcal{L}(r, \boldsymbol{\theta}, \mathbf{u})
 \end{aligned} \tag{6}$$

avec $\ell_c(\boldsymbol{\theta}; \mathbf{q}, \mathbf{u})$, log-vraisemblance complète, dont l'expression est la suivante :

$$\begin{aligned}
\ell_c(\boldsymbol{\theta}; \mathbf{q}, \mathbf{u}) &= \ln p(\mathbf{q}, \mathbf{u} \mid \boldsymbol{\theta}) \\
&= \sum_{t=1}^T \ln p(u_t \mid q_t, \boldsymbol{\mu}, \boldsymbol{\Sigma}) + \sum_{t=2}^T \sum_{i=1}^M \sum_{j=1}^M q_{t-1}^i q_t^j \ln A_{ij} + \sum_{i=1}^M q_1^i \ln \pi_i \\
&= \sum_{t=1}^T \sum_{k=1}^M q_t^k \left(-\ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_k| - \frac{1}{2} (u_t - \mu_k)^\top \boldsymbol{\Sigma}_k^{-1} (u_t - \mu_k) \right) \\
&\quad + \sum_{t=2}^T \sum_{i=1}^M \sum_{j=1}^M q_{t-1}^i q_t^j \ln A_{ij} + \sum_{i=1}^M q_1^i \ln \pi_i
\end{aligned} \tag{7}$$

On a donc une borne inférieure de la log-vraisemblance incomplète, $\mathcal{L}(r, \boldsymbol{\theta}, \mathbf{u})$. L'algorithme EM consiste en une montée alternée de cette borne inférieure par rapport à r et $\boldsymbol{\theta}$. En choisissant $r(\mathbf{q} \mid \mathbf{u}) = p(\mathbf{q} \mid \mathbf{u}, \boldsymbol{\theta})$, on maximise celle-ci, de sorte que les deux étapes de l'algorithme se résument de la manière suivante :

$$\begin{aligned}
E - \text{step} \quad r^{(s+1)} &= \arg \max_r \mathcal{L}(r, \boldsymbol{\theta}^{(s)}, \mathbf{u}) = p(\mathbf{q} \mid \mathbf{u}, \boldsymbol{\theta}^{(s)}) \\
M - \text{step} \quad \boldsymbol{\theta}^{(s+1)} &= \arg \max_{\boldsymbol{\theta}} \mathcal{L}(r^{(s+1)}, \boldsymbol{\theta}, \mathbf{u}) = \arg \max_{\boldsymbol{\theta}} \mathbb{E}_{r^{(s+1)}}(\ell_c(\boldsymbol{\theta}; \mathbf{q}, \mathbf{u}))
\end{aligned} \tag{8}$$

où s dénote le nombre d'itérations de l'algorithme.

D'après l'équation (7), on observe que $m_{ij} := \sum_{t=2}^T q_{t-1}^i q_t^j$ est la statistique exhaustive pour A_{ij} , que q_1^i est la statistique exhaustive pour π_i . Les estimateurs de maximum de log-vraisemblance complète pour A et π sont donc :

$$\hat{\pi}_i = q_1^i \tag{9}$$

$$\hat{A}_{ij} = \frac{m_{ij}}{\sum_{k=1}^M m_{ik}} \tag{10}$$

D'autre part, grâce aux calculs déjà effectués pour les estimateurs de vraisemblance de la mixture de gaussiennes, on obtient les estimateurs de log-vraisemblance complète des paramètres d'émission :

$$\widehat{\mu}_k = \frac{\sum_{t=1}^T q_t^k u_t}{\sum_{t=1}^T q_t^k} \tag{11}$$

$$\widehat{\boldsymbol{\Sigma}}_k = \frac{\sum_{t=1}^T q_t^k (u_t - \mu_k)(u_t - \mu_k)^\top}{\sum_{t=1}^T q_t^k} \tag{12}$$

Ces estimateurs doivent être pris sous l'espérance précise obtenue lors de l'étape E de l'algorithme EM, donnée par l'équation (8), afin que la maximisation de la log-vraisemblance complète induise une augmentation de la log-vraisemblance incomplète lors de l'itération $s+1$.

En reprenant l'estimateur de π obtenu en équation (9), on obtient l'estimateur à l'itération $(s+1)$:

$$\begin{aligned}
\hat{\pi}_i^{(s+1)} &= \mathbb{E}_{\mathbf{q} \mid \mathbf{u}, \boldsymbol{\theta}^{(s)}}[q_1^i] \\
&= \mathbb{E}_{q_1 \mid \mathbf{u}, \boldsymbol{\theta}^{(s)}}[q_1^i] \\
&= p(q_1^i = 1 \mid \mathbf{u}, \boldsymbol{\theta}^{(s)}) := \gamma_1^{i, (s+1)}
\end{aligned} \tag{13}$$

En reprenant l'estimateur de A_{ij} obtenue en équation (10), il faut déterminer $\mathbb{E}_{\mathbf{q}|\mathbf{u},\boldsymbol{\theta}^{(s)}}[m_{ij}]$.
On a :

$$\begin{aligned}\mathbb{E}_{\mathbf{q}|\mathbf{u},\boldsymbol{\theta}^{(s)}}[m_{ij}] &= \sum_{t=2}^T \mathbb{E}_{\mathbf{q}|\mathbf{u},\boldsymbol{\theta}^{(s)}}[q_{t-1}^i q_t^j] \\ &= \sum_{t=2}^T p(q_{t-1}^i = 1, q_t^j = 1 \mid \mathbf{u}, \boldsymbol{\theta}^{(s)}) \\ &:= \sum_{t=2}^T \xi_{t-1,t}^{ij,(s+1)}\end{aligned}$$

D'où l'estimateur à l'itération $(s+1)$ pour A :

$$\hat{A}_{ij}^{(s+1)} = \frac{\sum_{t=2}^T \xi_{t-1,t}^{ij,(s+1)}}{\sum_{k=1}^M \sum_{t=2}^T \xi_{t-1,t}^{ik,(s+1)}} = \frac{\sum_{t=2}^T \xi_{t-1,t}^{ij,(s+1)}}{\sum_{t=2}^T \gamma_{t-1}^{i,(s+1)}} \quad (14)$$

De la même façon, on obtient les estimateurs à l'itération $(s+1)$ pour les μ_k et Σ_k :

$$\begin{aligned}\widehat{\mu}_k^{(s+1)} &= \frac{\sum_{t=1}^T \gamma_t^{k,(s+1)} u_t}{\sum_{t=1}^T \gamma_t^{k,(s+1)}} \quad \forall k \in \llbracket 1; M \rrbracket \\ \widehat{\Sigma}_k^{(s+1)} &= \frac{\sum_{t=1}^T \gamma_t^{k,(s+1)} \left(u_t - \mu_k^{(s)}\right) \left(u_t - \mu_k^{(s)}\right)^\top}{\sum_{t=1}^T \gamma_t^{k,(s+1)}} \quad \forall k \in \llbracket 1; M \rrbracket\end{aligned} \quad (15)$$

L'implémentation du calcul des γ et ξ est succinctement détaillée et fait intervenir le calcul des α_{norm} du problème de *filtering*.

$$\begin{aligned}\gamma_t(q_t) &= p(q_t \mid u_1, \dots, u_T) \\ &= \sum_{q_{t+1}} p(q_t, q_{t+1} \mid u_1, \dots, u_T) \\ &= \sum_{q_{t+1}} \frac{\alpha_t(q_t) A_{q_t, q_{t+1}}}{\sum_{q_t} \alpha_t(q_t) A_{q_t, q_{t+1}}} \gamma_{t+1}(q_{t+1})\end{aligned} \quad (16)$$

$$\begin{aligned}\xi_{t,t+1}(q_t, q_{t+1}) &= p(q_t, q_{t+1} \mid \mathbf{u}) \\ &= \frac{\alpha_t(q_t) p(u_{t+1} \mid q_{t-1}) \gamma_{t+1}(q_{t+1}) A_{q_t, q_{t+1}}}{\alpha_{t+1}(q_{t+1})}\end{aligned} \quad (17)$$