

---

# COMPTE-RENDU DU DEVOIR 3

Vincent Matthys

---

## 1 HMM implementation

On notera  $\mathbf{u} = \{u_i\}_{i \in [1;T]}$  et  $\mathbf{q} = \{q_i\}_{i \in [1;T]}$

### 1.1

Le problème de l'inférence dans la chaîne de Markov modélisée, à savoir le calcul de  $p(\mathbf{q} \mid \mathbf{u})$  est appréhendable par le calcul de la marginale  $p(q_t \mid \mathbf{u})$  suivant :

$$\begin{aligned}
 p(q_t \mid \mathbf{u}) &= \frac{p(\mathbf{u} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
 &= \frac{p(u_1, \dots, u_t \mid q_t)p(u_{t+1}, \dots, u_T \mid q_t)p(q_t)}{p(\mathbf{u})} \quad u_1, \dots, u_t \perp\!\!\!\perp u_{t+1}, \dots, u_T \mid q_t \\
 &= \frac{p(u_1, \dots, u_t, q_t)p(u_{t+1}, \dots, u_T \mid q_t)}{p(\mathbf{u})} \\
 &= \frac{\alpha_t(q_t)\beta_t(q_t)}{p(\mathbf{u})} \\
 &= \frac{\alpha_t(q_t)\beta_t(q_t)}{\sum_{q_t} \alpha_t(q_t)\beta_t(q_t)} \\
 &= \frac{\alpha_t(q_t)\beta_t(q_t)}{\sum_{q_T} \alpha_T(q_T)} \quad \text{puisque} \quad p(\mathbf{u}) = \sum_{q_T} p(q_T, \mathbf{u}) = \sum_{q_T} \alpha_T(q_T)
 \end{aligned} \tag{1}$$

avec  $\alpha_t(q_t) = p(u_1, \dots, u_t, q_t)$  et  $\beta_t(q_t) = p(u_{t+1}, \dots, u_T \mid q_t)$

On peut alors aussi exprimer  $p(q_t, q_{t+1} \mid \mathbf{u})$  en fonction de  $\alpha_t$  et  $\beta_t$  :

$$\begin{aligned}
p(q_t, q_{t+1} \mid \mathbf{u}) &= \frac{p(\mathbf{u} \mid q_t, q_{t+1})p(q_t, q_{t+1})}{p(\mathbf{u})} \\
&= \frac{p(\mathbf{u} \mid q_t, q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t \mid q_t, q_{t+1})p(u_{t+1}, \dots, u_T \mid q_t, q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t \mid q_t)p(u_{t+1}, \dots, u_T \mid q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t \mid q_t)p(u_{t+1} \mid q_{t+1})p(u_{t+2}, \dots, u_T \mid q_{t+1})p(q_{t+1} \mid q_t)p(q_t)}{p(\mathbf{u})} \\
&= \frac{p(u_1, \dots, u_t, q_t)p(u_{t+1} \mid q_{t+1})p(u_{t+2}, \dots, u_T \mid q_{t+1})p(q_{t+1} \mid q_t)}{p(\mathbf{u})} \\
&= \frac{\alpha_t(q_t)p(u_{t+1} \mid q_{t+1})\beta_t(q_{t+1})A_{q_t, q_{t+1}}}{p(\mathbf{u})}
\end{aligned} \tag{2}$$

où  $A_{q_t, q_{t+1}} = p(q_{t+1} \mid q_t)$  et  $p(u_{t+1} \mid q_{t+1})$  suit une loi gaussienne.

À des fins d'implémentation, on considèrera les logarithmes des  $\alpha$  et  $\beta$ ,  $\tilde{\alpha}$  et  $\tilde{\beta}$  de sorte que les formules de récursion peuvent se réécrire :

$$\begin{cases} \ln \alpha_t(q_t) = \ln p(u_t \mid q_t) + \ln \sum_{q_{t-1}} (e^{\ln \alpha_{t-1}(q_{t-1})} A_{q_{t-1}, q_t}) \\ \ln \beta_t(q_t) = \ln \sum_{q_{t+1}} (e^{\ln \beta_{t+1}(q_{t+1})} A_{q_t, q_{t+1}} p(y_{t+1} \mid q_{t+1})) \end{cases} \tag{3}$$

$$\begin{cases} \tilde{\alpha}_t(q_t) = \ln p(u_t \mid q_t) + \ln \sum_{q_{t-1}} (e^{\tilde{\alpha}_{t-1}(q_{t-1})} A_{q_{t-1}, q_t}) \\ \tilde{\beta}_t(q_t) = \ln \sum_{q_{t+1}} (e^{\tilde{\beta}_{t+1}(q_{t+1})} A_{q_t, q_{t+1}} p(y_{t+1} \mid q_{t+1})) \end{cases} \tag{4}$$

et que la tâche d'inférence dite de filtrage en équation (1) s'écrit :

$$\begin{aligned}
\ln p(q_t \mid \mathbf{u}) &= \ln \alpha_t(q_t) + \ln \beta_t(q_t) - \ln \sum_{q_T} \alpha_T(q_T) \\
\ln p(q_t \mid \mathbf{u}) &= \tilde{\alpha}_t(q_t) + \tilde{\beta}_t(q_t) - \ln \sum_{q_T} e^{\tilde{\alpha}_T(q_T)}
\end{aligned} \tag{5}$$

## 2

### 2.1

$$\begin{aligned}
X \perp\!\!\!\perp Y \mid Z &\Leftrightarrow p(x, y \mid z) = p(x \mid z)p(y \mid z) \quad \forall x, y, z \quad \text{t.q.} \quad p(z) > 0 \\
&\Leftrightarrow p(x, y, z) = p(x \mid z)p(y \mid z)p(z) \quad \forall x, y, z \quad \text{t.q.} \quad p(z) > 0 \\
&\Leftrightarrow \frac{p(x, y, z)}{p(y, z)} = p(x \mid z) \frac{p(y \mid z)p(z)}{p(y, z)} \quad \forall x, y, z \quad \text{t.q.} \quad p(y, z) > 0 \\
&\Leftrightarrow p(x \mid y, z) = p(x \mid z) \quad \forall x, y, z \quad \text{t.q.} \quad p(y, z) > 0
\end{aligned} \tag{6}$$

## 2.2

Etant donné le modèle graphique orienté  $G$  :

$$p \in \mathcal{L}(G) \Leftrightarrow \forall x, y, z, t \quad p(x, y, z, t) = p(x)p(y)p(z \mid x, y)p(t \mid z) \quad (7)$$

## 2.3

*Non traité.*

# 3 Distributions factorisant sur un graphe

## 3.1

*Non traité.*

## 3.2

*Non traité.*

## 4 Entropie et information mutuelle

### 4.1 Entropie

#### 4.1.a)

Avec les conventions définies :

$$p_X(x) = \mathbb{P}(X = x) < 1 \Rightarrow p_X(x) \log(p_X(x)) < 0 \Rightarrow - \sum_{x \in \mathcal{X}} p_X(x) \log(p_X(x)) = H(X) \geq 0$$

$$H(X) = 0 \Rightarrow \forall x \in \mathcal{X}, p_X(x) \log(p_X(x)) = 0 \Rightarrow \forall x \in \mathcal{X}, p_X(x) = 1 \Rightarrow X \text{ is constant with probability 1} \quad (8)$$

#### 4.1.b)

Par définition de la Kullback-Leibler divergence il vient :

$$\begin{aligned} D(p_X \parallel q) &= \sum_{x \in \mathcal{X}} p_X(x) \log \frac{p_X(x)}{q(x)} \\ &= - \sum_{x \in \mathcal{X}} p_X(x) \log q(x) - H(X) \\ &= - \sum_{x \in \mathcal{X}} p_X(x) \log \frac{1}{|\mathcal{X}|} - H(X) \quad \text{puisque} \quad \forall x \in \mathcal{X}, q(x) = \frac{1}{k} = \frac{1}{k} \quad (9) \\ &= \log k \sum_{x \in \mathcal{X}} p_X(x) - H(X) \\ &= \log k - H(X) \quad \text{car} \quad \sum_{x \in \mathcal{X}} p_X(x) = 1 \end{aligned}$$

#### 4.1.c)

Avec les équations (8) et (9), on a directement

$$\log k - H(X) = D(p_X \parallel q) \leq \log k \quad (10)$$

### 4.2 Information mutuelle

#### 4.2.a)

Par définition de l'information mutuelle :

$$I(X_1, X_2) = \sum_{(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2} p_{1,2}(x_1, x_2) \log \frac{p_{1,2}(x_1, x_2)}{p_1(x_1) p_2(x_2)} \quad (11)$$

$$I(X_1, X_2) = D(p_{1,2} \parallel p_1 p_2) \quad \text{par définition de la Kullback-Leibler divergence}$$

Or la Kullback-Leibler divergence est positive pour toute paire  $(p_{1,2}, p_1 p_2)$  de distributions, donc  $I(X_1, X_2) \geq 0$ .

#### 4.2.b)

Toujours avec la définition de l'information mutuelle :

$$\begin{aligned}
I(X_1, X_2) &= \sum_{(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2} p_{1,2}(x_1, x_2) \log \frac{p_{1,2}(x_1, x_2)}{p_1(x_1) p_2(x_2)} \\
I(X_1, X_2) &= \sum_{(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2} p_{1,2}(x_1, x_2) \log p_{1,2}(x_1, x_2) \\
&\quad - \sum_{(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2} p_{1,2}(x_1, x_2) \log (p_1(x_1) p_2(x_2)) \\
I(X_1, X_2) &= -H(X_1, X_2) \\
&\quad - \sum_{x_1 \in \mathcal{X}_1} \left( \sum_{x_2 \in \mathcal{X}_2} p_{1,2}(x_1, x_2) \right) \log (p_1(x_1)) \\
&\quad - \sum_{x_2 \in \mathcal{X}_2} \left( \sum_{x_1 \in \mathcal{X}_1} p_{1,2}(x_1, x_2) \right) \log (p_2(x_2)) \\
I(X_1, X_2) &= -H(X_1, X_2) \\
&\quad - \sum_{x_1 \in \mathcal{X}_1} p_1(x_1) \log (p_1(x_1)) \\
&\quad - \sum_{x_2 \in \mathcal{X}_2} p_2(x_2) \log (p_2(x_2)) \\
I(X_1, X_2) &= H(X_1) + H(X_2) - H(X_1, X_2)
\end{aligned} \tag{12}$$

Et ainsi l'information mutuelle peut s'écrire uniquement à partir des entropies de  $X_1$ ,  $X_2$  et de  $(X_1, X_2)$ .

#### 4.2.c)

D'après l'équation (12), on peut réécrire :

$$\begin{aligned}
H(X_1, X_2) - (H(X_1) + H(X_2)) &= -I(X_1, X_2) \\
H(X_1, X_2) - (H(X_1) + H(X_2)) &\leq 0 \quad \text{puisque, } I(X_1, X_2) \geq 0
\end{aligned} \tag{13}$$

D'après l'équation (13), pour  $p_1$  et  $p_2$  données, l'entropie maximale correspond à  $I(X_1, X_2) = 0$ , c'est-à-dire  $D(p_{1,2} \parallel p_1 p_2) = 0$  d'après l'équation (9). Or la Kullback-Leibler divergence s'annule si et seulement si les distributions sont identiques. On a alors  $p_{1,2} = p_1 p_2$ , ce qui correspond à  $X_1 \perp\!\!\!\perp X_2$ .

## 5 Gaussian Mixtures

### 5.1 K-means